浙江理工大学科技与艺术学院

KEYI COLLEGE OF ZHEJIANG SCI-TECH UNIVERSITY

程序设计基础课程设计

任务指导书



叶杰锋 编

2025 年 12 月

一、任务目标

掌握 Python 网络爬虫的基本概念、原理和常用库，如 requests、BeautifulSoup 等。了解网络爬虫的分类、爬取策略和工作原理，以及与之相关的数据解析、持久化存储等知识。运用 Python 网络爬虫实现对网页数据的抓取、解析和分析。运用所学知识，爬取合法爬取数据，禁止爬取政府、学术数据库等用户信息或知识产权敏感型网站。爬取到的数据需要解析并规范化输出，可将数据持久化到以下数据库，包括但不限于 MySQL、Redis、MongoDB。将获取到的数据从数据库取出，做进一步的处理，例如完成一个由爬取到的数据组成的应用系统，如小程序、APP、Web 等，或做相应的数据处理和分析，如数据可视化统计与展示等。

二、任务要点

- 需求整理阶段，整理所要爬取的站带你内容，并绘制爬虫的一个流程图
- 禁止爬取豆瓣、知乎站点
- 爬取的站点包括但不限于以下平台类别：
  - 新闻聚合平台：新浪微博、微信公众号、腾讯新闻
  - 电商聚合平台：京东、淘宝、美团
  - 求职招聘平台：BOSS 直聘、58 同城
  - 视频聚合平台：B 站、抖音、快手
  - 财经聚合平台：同花顺、财联社、雪球

- 其他自定义的平台

- 爬取的数据量需要符合课设的工作量时长
- 爬取的持久化平台可以选择：Redis、MongoDB、MySQL 等
- 爬取的技术栈不限制，如 requests、selenium、scrapy 等
- 爬取过程中需要有分析 Network 请求及构造的过程
- 爬虫代码可以使用函数式编程，也可以使用类编程（更建议），所有代码的格式风格统一，命名规范（方法名、变量名等）
- 爬取后的数据需要取出做一个应用，加以展示输出使用，系统的开发可以使 Web 页面、小程序、APP、桌面端等，系统界面美观，运行流畅

三、时间安排

地点：C6-302

时间：第 14 周

四、成果展示

1. 报告提交：文件夹以“学号-姓名-题目”命名（命名不规范扣分），其中包含项目代码文件夹，以及以“学号-姓名-题目.pdf”命名的报告文档，并打印。报告内容需按照所给出的模版编写，应有设计题目、需求分析、设计步骤思路、设计心得体会等。

2. 考核成绩：平时表现与考勤 20%，项目报告 30%，成果展示与现场检查 50%。